TP Classification

Data preprocessing and exploration

1) Importer les bibliothèques nécessaires (pandas, numpy, seaborn, matplotlib, warnings, …).
2) Télécharger le fichier Churn_Modelling.csv.

3) Afficher les données de ce fichier.

4) Donner la taille du dataSet.

5) Afficher tous les noms de colonnes du DataFrame sous forme de liste.
6) Supprimer les 3 premières colonnes et afficher de nouveau les données
7) Identifier et compter les valeurs manquantes (NaN) dans chaque colonne du DataFrame df.

8) Donner un aperçu rapide de la structure de votre DataFrame, vérifier les types de données, et identifier les colonnes qui pourraient contenir des valeurs manquantes.

9) Donner des statistiques descriptives sur les colonnes numériques.
10) Calculer le taux de churn (ou taux d'abandon) dans votre DataFrame df en utilisant la colonne Exited.
11) Donnez une decsription des valriables de dtype object
12) Donnez toutes les valeurs uniques présentes dans la colonne Geography du DataFrame df.
13) Donnez le nombre de clients par Geography

14) Créer une liste par les variables ‘Balance’ et ‘ EstimatedSalary’

15) Affichez les Boxplot des variables de my_list

16) Donnez le Boxplot du variable ‘CreditScore’

17) Quel est le taux des clients ayant un score CreditCard inférieur ou égal à la borne Inf qui ont abandonné (Exited = 1) ?
18) calcule le taux de churn (c'est-à-dire le pourcentage de clients qui ont quitté la banque) pour les clients âgés entre 45 et 55 ans inclus.

19) Diviser vos données entre données explicatives (descripteurs) et données cibles.
20) convertit les DataFrames X et y en tableaux NumPy (ndarray).
21) Convertir les variables catégorielles en variables numériques
22) Diviser vos données entre 80% pour l’apprentissage et 20% pour le test.
23) Comparer le taux de churn entre l’ensemble d’apprentissage et celui de test. Qu’est-ce que vous remarquez ?
24) Normaliser vos données.

Modélisation

1) Appliquer la classification par le plus proche voisin.
2) Calculer les métriques d'évaluation pour cette classification.
3) Appliquer la validation croisée et déterminer le meilleur nombre de voisins à considérer pour cet échantillon.
4) Appliquer la classification par la forêt aléatoire (Random Forest) et Calculer les métriques d'évaluation.
5) Extraire les meilleurs descripteurs pour la détection de churn.

6) Appliquer la classification par le SVM et Calculer les métriques d'évaluation.

7) Appliquer la classification par la régression logistique et Calculer les métriques d'évaluation.

8) Comparer toutes ces méthodes de classification par une courbe ROC.